Aprendizaje por refuerzo para operar un activo

Q-learning, Sarsa y Monte Carlo en mercados simulados y series reales

Josep Perez Segura · Natalia SanJosé Ortega · Emilio Sánchez Martínez
Taller de Aprendizaje por Refuerzo · MIAX-14 · octubre de 2026

Resumen. Se entrenan agentes tabulares para decidir cuándo comprar, mantener o vender un activo. En cuatro mercados simulados, Q-learning, Sarsa y control Monte Carlo aprenden políticas acordes con la señal disponible: siguen tendencias, aprovechan la reversión o evitan operar cuando no hay una ventaja clara. En datos reales, los resultados no se trasladan de forma consistente y ningún agente supera con claridad a comprar y mantener.

Entorno y método

Se usa el entorno de trading tal como está definido en el enunciado dado. En cada paso, el agente observa la tendencia del precio respecto a la media de las seis últimas cotizaciones y si ya posee el activo. Puede vender, mantener o comprar; cada transacción paga una comisión del 0,1 %. Se prueban los cuatro generadores propuestos: tendencia con ciclo, movimiento browniano, reversión a la media y alternancia de regímenes alcistas y bajistas.

Como la escala de la tendencia varía entre mercados, se discretiza en intervalos simétricos alrededor de cero. Se implementan Q-learning, Sarsa y, como extensión, control Monte Carlo on-policy, con exploración ε-greedy. La comparación incluye cuatro referencias: una política aleatoria, comprar y mantener, y dos reglas basadas en momentum y contrarian.

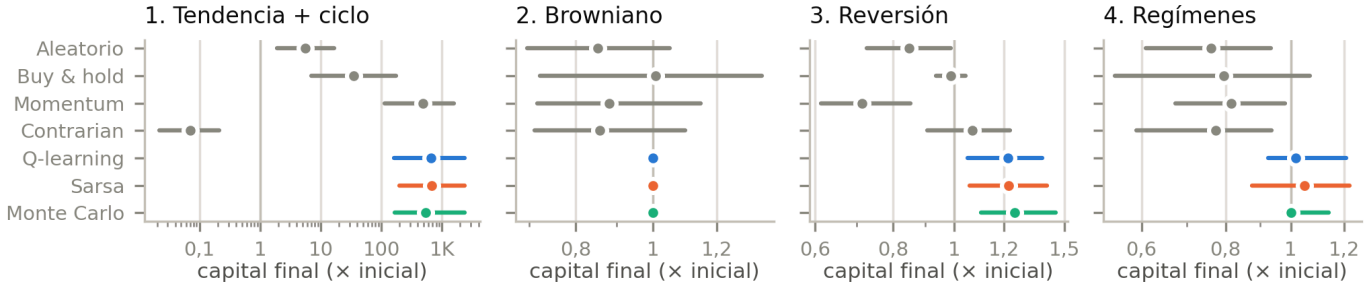
Cada episodio de entrenamiento usa una serie nueva de 500 pasos. El ajuste de hiperparámetros se hace por etapas y exclusivamente con validación: primero α y γ, después el número de intervalos y el calendario de ε. Se evalúan configuraciones con tres semillas y 100 series de validación. Para el test se reservan 100 series nuevas por mercado y diez semillas de entrenamiento que no intervienen en el ajuste. Los agentes y las referencias se comparan sobre las mismas series. La tabla resume la mediana del retorno porcentual de test; también se analizan Sharpe, drawdown, operaciones y comparaciones pareadas con intervalos bootstrap.

Resultados en los mercados simulados

Mercado	Q-learning	Sarsa	Monte Carlo	Referencia destacada
Tendencia y ciclo	+64.989 %	+67.861 %	+53.896 %	Momentum: +48.189 %
Browniano	0 %	0 %	0 %	Buy & hold: +0,7 %
Reversión a la media	+21,96 %	+22,17 %	+24,91 %	Contrarian: +6,9 %
Regímenes	+1,68 %	+4,70 %	0 %	Buy & hold: −20,4 %

Retorno mediano en test. Para cada agente de RL se evalúan diez entrenamientos sobre las mismas cien series de cada mercado. En el browniano, cero corresponde a no operar.

Lectura principal. En el ciclo, Sarsa supera a la regla momentum y opera aproximadamente un tercio de veces, gracias a una política con histéresis. En reversión, Monte Carlo obtiene el mayor retorno. En regímenes, Q-learning y Sarsa logran una mejora modesta; la variabilidad entre semillas aconseja interpretarla con cautela.



Capital final en test: mediana y rango intercuartílico; escala logarítmica.

Resultados e interpretación

Qué aprendimos y hasta dónde generaliza

Interpretación por mercado

Tendencia y ciclo. Los agentes aprenden momentum con histéresis: entran cuando la tendencia es claramente positiva y esperan una señal claramente negativa para salir. Sarsa obtiene una mediana del +67.861 %, frente al +48.189 % de la regla momentum; la comparación pareada estima una ventaja de 1,37 veces (IC del 95 %: 1,15–1,61). El ruido elevado del generador hace que estos retornos extremos no sean representativos de un mercado real.

Browniano. La mediana es cero porque las políticas suelen quedarse fuera. No se detecta una ventaja clara frente a comprar y mantener; las reglas que operan con frecuencia pierden por comisiones. Una de las diez semillas de Q-learning ajustado opera y pierde, por lo que el retorno medio es ligeramente negativo aunque la mediana siga en cero.

Reversión a la media. Los tres algoritmos aprenden una estrategia contrarian selectiva y superan a la regla fija. Monte Carlo alcanza +24,91 % y supera a Sarsa en la comparación controlada en un 4 % de capital geométrico (IC: 1,02–1,05). En este entorno, el retorno completo reduce el sesgo del bootstrap sobre un estado que no contiene toda la información relevante.

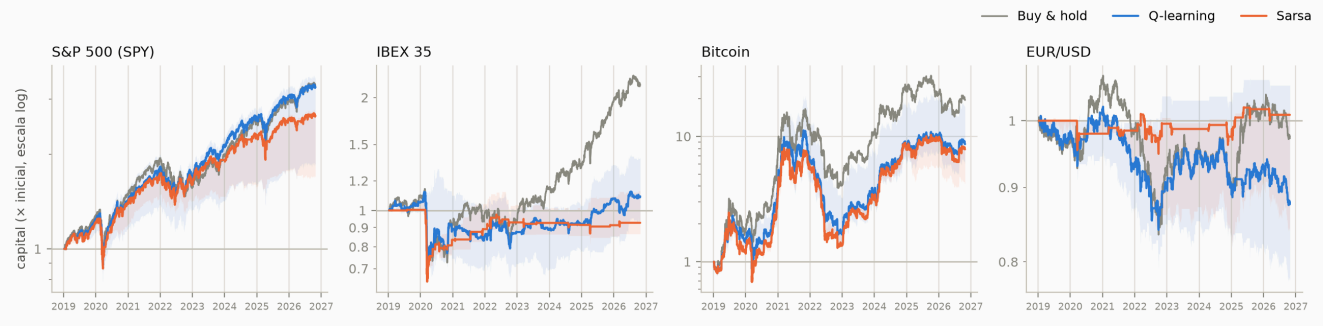
Regímenes. Q-learning y Sarsa mejoran ligeramente frente a no operar, y quedan muy por encima de buy & hold en este mercado bajista simulado. La magnitud de la tendencia parece servir como aproximación de la volatilidad. Monte Carlo, en cambio, obtiene una mediana de cero: con horizontes largos, la varianza del retorno acumulado dificulta aprender cuándo mantener la posición.

La prueba con datos reales

El entrenamiento utiliza precios diarios hasta 2018 y reserva el periodo 2019–octubre de 2026 como un único episodio de test por activo. Se fijan dos configuraciones de hiperparámetros antes de consultar esos resultados. La siguiente comparación muestra buy & hold y el mejor resultado de Q-learning o Sarsa con la configuración de regímenes:

Activo	Buy & hold	Mejor agente	Retorno
S&P 500	+232 %	Q-learning	+228 %
IBEX 35	+117 %	Q-learning	+9 %
Bitcoin	+1.850 %	Q-learning	+767 %
EUR/USD	−2,8 %	Sarsa	+0,9 %

El resultado de EUR/USD es una excepción favorable, pero procede de una sola trayectoria y no demuestra una ventaja generalizable. En conjunto, el rendimiento alto durante el entrenamiento no se mantiene de manera consistente en el periodo de test.



Capital en el periodo real de test, normalizado al capital inicial; bandas: variabilidad entre semillas.

Conclusiones y límites

Los experimentos controlados muestran que los agentes pueden descubrir políticas útiles cuando la señal del mercado es explotable, y abstenerse cuando operar no compensa. Las diferencias entre Q-learning y Sarsa son pequeñas en la mayoría de los casos; algunas comparaciones pareadas detectan diferencias estadísticamente significativas, pero su tamaño y la variabilidad entre semillas no justifican una conclusión general sobre qué algoritmo es mejor. Monte Carlo aporta un contraste didáctico: puede beneficiarse de evitar el bootstrap en reversión, pero sufre la varianza en horizontes largos.

En validación, Q-learning y Sarsa alcanzan la estabilización entre 200 y 3700 episodios. Monte Carlo requiere hasta 3800 episodios y su curva todavía mejora en el mercado de regímenes al llegar a 4000, en línea con la mayor varianza de sus retornos acumulados.

La evidencia tiene límites importantes. El estado solo incluye una tendencia de seis pasos y la posición, la comisión es fija y los mercados simulados son estacionarios. El ajuste entre muchas configuraciones y pocas semillas puede sobreajustar la validación. En datos reales hay una sola historia de test por activo, así que las diez semillas miden variabilidad del entrenamiento, no incertidumbre de mercado. Un paso siguiente razonable sería evaluar con ventanas móviles, añadir volatilidad y tendencias de largo plazo al estado y ampliar el número de trayectorias.