Q-learning, Sarsa y Monte Carlo para invertir en un activo: cuatro mercados simulados

Josep Perez Segura · Natalia SanJosé Ortega · Emilio Sánchez Martínez

Taller de Aprendizaje por Refuerzo · MIAX-14 · octubre de 2026

Resumen. Entrenamos agentes tabulares Q-learning y Sarsa y, como extra, control Monte Carlo (MC) en el entorno del enunciado, sin modificarlo, con los cuatro generadores de precios. Los comparamos con el agente aleatorio, *buy & hold* (B&H) y dos reglas fijas (*momentum* y *contrarian*) en 100 series de test nuevas por mercado. Los agentes aprenden la estrategia esperada: seguir la tendencia donde hay inercia, ir contra ella donde hay reversión y no operar donde no hay señal. Superan a todas las referencias, salvo en el browniano, donde no hay nada que explotar.

1. Diseño experimental

- **Estado.** La tendencia es continua y su escala cambia mucho entre mercados (ruido del 10 % por paso en el ciclo y del 1–2,5 % en el resto). La dividimos en k intervalos **simétricos, con el 0 como corte**, según cuantiles de |tendencia| de cada mercado: visitas parecidas por intervalo y ninguno mezcla signos; con la posición, $2k$ estados.
- **Acciones y γ.** El agente solo decide si está dentro o fuera, y no influye en la tendencia. Sin comisiones bastaría con $\gamma = 0$; γ sirve para anticipar lo que costará entrar y salir.
- **Algoritmos.** Q-learning, Sarsa y, como extra, control MC *on-policy* de primera visita o de todas las visitas (slides 2). Todos son ε-greedy, con ε decreciendo exponencialmente de 1 a ε_f, y usan α constante o $\alpha = 1/n(s,a)^{\omega}$ con $0{,}5 < \omega \leq 1$, que cumple $\sum \alpha = \infty$ y $\sum \alpha^2 < \infty$.
- **Datos y métricas.** Cada episodio usa una serie nueva de 500 pasos; validación y test (100 series cada uno) usan semillas disjuntas y son comunes a todos los agentes. Métrica principal: la mediana del retorno (en el ciclo, unas pocas series dominan la media). **Convergencia:** episodio desde el que la mediana en validación queda a menos de un 10 % (o 1 punto) de su valor final.

Estrategia esperada. Antes de entrenar medimos el retorno medio del paso siguiente en cada intervalo de tendencia: mucha inercia en el ciclo (de −2,5 % a +4,5 %), nada en el browniano, señal contraria en la reversión (solo los extremos superan la comisión) y una señal débil en regímenes. Esperamos *momentum*, no operar, *contrarian* selectivo y, en regímenes, poco que ganar.

2. Ajuste de hiperparámetros

Por etapas y solo en validación (3 semillas × 100 series; 864 entrenamientos para TD y 660 para MC):

- **Etapa A:** $\alpha \in \{0{,}01;\ 0{,}001;\ 1/n^{0{,}6};\ 1/n^{0{,}8};\ 1/n\} \times \gamma \in \{0;\ 0{,}5;\ 0{,}9;\ 0{,}99\}$ (× primera visita o todas, en MC).
- **Etapa B:** con lo mejor de A, $k \in \{4, 6, 10, 16, 20\}$ × tres calendarios de ε.
- **Etapa C, episodios:** con 6000, la validación se estabiliza a los 4000 en todos los mercados (con 2000, Sarsa aún iba por el 0,2 % en regímenes, frente al 6,5 % final): entrenamos con **4000**. El ajuste usó 2000 por coste, lo que puede penalizar a los α pequeños.

Elegidos: $\gamma = 0$ en ciclo y browniano (la señal es de un paso y un γ alto solo añade ruido); $\gamma = 0{,}5$ y $k = 16$–20 en reversión; $\alpha = 0{,}001$ constante, $\gamma \geq 0{,}9$ y $k = 16$–20 en regímenes, donde los valores por defecto casi no operaban. MC elige lo mismo, salvo $\gamma = 0{,}5$ en regímenes.

3. Resultados en test

Tabla 1: Mediana del retorno porcentual en test y Sharpe medio; 100 series por mercado (× 10 semillas nuevas para RL). Convergencia: mediana entre semillas; sin segundos para MC, que se entrenó en otro equipo (el coste por episodio es similar).

Agente	Tendencia + ciclo	Browniano	Reversión	Regímenes
Aleatorio	+456 (1,3)	−14,7 (−0,3)	−15,2 (−0,3)	−23,9 (−0,6)
Buy & hold	+3.425 (1,9)	+0,7 (0,1)	−1,1 (0,1)	−20,4 (−0,3)
Momentum	+48.189 (3,1)	−11,8 (−0,2)	−28,7 (−0,6)	−18,4 (−0,4)
Contrarian	−92,9 (−0,7)	−14,3 (−0,2)	+6,9 (0,3)	−22,6 (−0,5)
Q-learning	**+64.989 (3,2)**	0 (−0,1)	**+22,0 (0,5)**	**+1,7 (0,3)**
Sarsa	**+67.861 (3,2)**	0 (0,0)	**+22,2 (0,5)**	**+4,7 (0,2)**
Monte Carlo	**+53.896 (3,0)**	0 (0,0)	**+24,9 (0,6)**	0 (0,2)
Convergencia Q-learning	2600 ep. · 24 s	500 ep. · 5 s	3300 ep. · 30 s	2900 ep. · 28 s
Convergencia Sarsa	600 ep. · 4 s	200 ep. · 2 s	3700 ep. · 29 s	2000 ep. · 16 s
Convergencia MC	3100 ep.	600 ep.	3500 ep.	3800 ep.

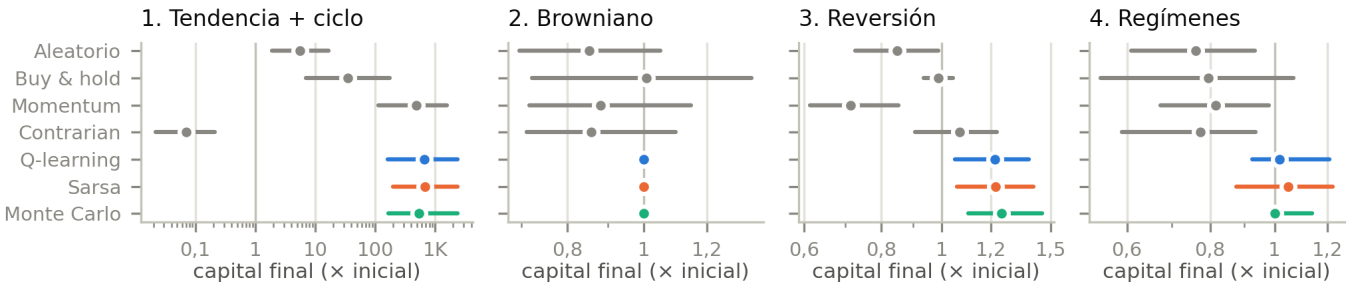


Figura 1: Capital final en test por agente y mercado: mediana (punto) y percentiles 25–75 (línea).

"×": cociente geométrico medio del capital final entre dos agentes en las mismas series de test, con IC bootstrap del 95 %. Los agentes de RL superan al aleatorio en todos los mercados (fuera del ciclo, este pierde un 15–24 %).

- **Ciclo: *momentum* con histéresis, el esperado.** Superan a *momentum* (Sarsa ×1,37 [1,15; 1,61]) y a B&H (×18) con un tercio de sus operaciones: compran con tendencia muy positiva y venden solo si es muy negativa (Fig. 2).
- **Browniano: no operar, el esperado (con un matiz, §4).** Salvo 1 semilla de Q-learning, no compran, y evitan lo que pierden las reglas en comisiones (−12 % a −15 %). Frente a B&H, ×1,01 [0,93; 1,10].
- **Reversión: *contrarian* selectivo, el esperado.** Compran en los intervalos más bajistas y mantienen hasta los más alcistas: ×1,14 [1,09; 1,20] frente a la regla *contrarian*, con un cuarto de sus operaciones, y ×1,24 frente a B&H.
- **Regímenes: mejor de lo esperado.** Compran con tendencia positiva moderada y venden ante movimientos extremos en cualquier sentido: el tamaño de la tendencia aproxima la volatilidad, que separa el régimen alcista tranquilo del bajista volátil. Ganan a no operar (Q-learning ×1,06 [1,03; 1,10]) y con holgura a B&H y *momentum* (×1,38 y ×1,30).

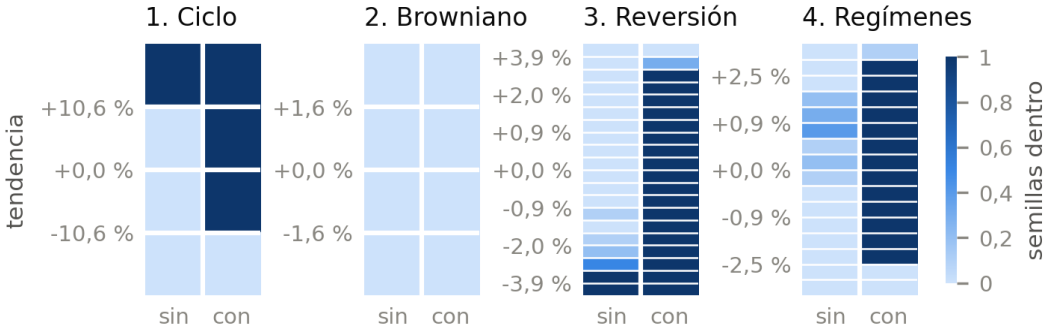


Figura 2: Políticas de Sarsa: fracción de las 10 semillas dentro del mercado en cada estado (tendencia × posición, sin o con el activo). Las de Q-learning y MC son muy parecidas, salvo MC en regímenes, que apenas compra.

Q-learning, Sarsa y Monte Carlo. Q-learning y Sarsa no difieren de forma significativa: con $\gamma = 0$ hacen la misma actualización, y explorar cuesta como mucho una comisión (no hay un "acantilado" como en *Cliff Walking*). Para MC aislamos el efecto del objetivo, el retorno real G_t frente a $R_{t+1}+\gamma Q(S_{t+1}, A_{t+1})$, entrenándolo con los hiperparámetros de Sarsa. Con $\gamma = 0$ dan la misma política (×1,00). Con $\gamma = 0{,}5$ (reversión), MC mejora (×1,04 [1,02; 1,05]) y varía menos entre semillas (medianas del 22 % al 28 %, frente al 13–25 % de Sarsa): no hace *bootstrap* sobre un estado no markoviano, al que le falta la distancia a la media. Con $\gamma = 0{,}99$ (regímenes) empeora (×0,94 [0,91; 0,97]), porque G_t suma decenas de retornos ruidosos. Es el compromiso sesgo-varianza entre MC y TD visto en clase.

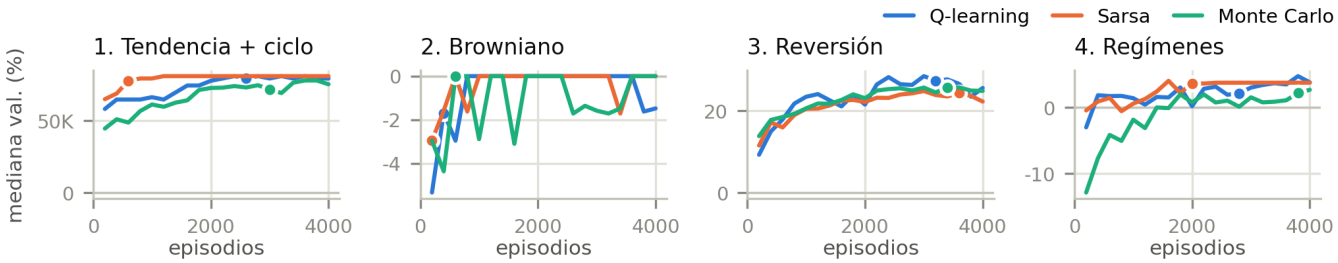


Figura 3: Curvas de aprendizaje: mediana del retorno en validación (media de 10 semillas), cada 200 episodios; el punto marca la convergencia.

Convergencia (Figura 3). Con un coste por episodio similar, el tiempo es proporcional a los episodios: TD converge en 200–3700 (2–30 s) y MC necesita más en tres mercados, y en regímenes aún mejora a los 4000 (otra cara de su varianza). El ajuste ralentiza a TD (α menores), pero mejora la configuración por defecto en ciclo (×1,18–1,19) y regímenes (×1,05).

4. Análisis crítico y conclusiones

- **Conclusión principal.** Con señal, los tres algoritmos encuentran la estrategia esperada y la mejoran con histéresis; sin señal, no operan. Las diferencias entre ellos se explican por la teoría (sesgo y varianza), no por el azar.
- **Lo "esperado" depende de la métrica.** En el browniano, la recompensa del entorno (retorno simple) tiene esperanza positiva (+0,01 % por paso), y para ella, con γ alto, lo óptimo es B&H. Pero el log-retorno la tiene negativa ($\mu - \sigma^2/2 = -0{,}01$ %) y la mediana del capital cae. Con $\gamma = 0{,}99$, 14 de 30 entrenamientos aprendieron B&H (media en validación de +9 %, mediana negativa): elegir por mediana favorece no operar.
- **El ajuste en validación es optimista.** En reversión, la mejora en validación (26 % frente a 19–21 %) desaparece en test (×1,01 y ×1,03, no significativas), y en ciclo el MC elegido rinde menos que con la configuración de Sarsa (×0,87): elegir entre muchas configuraciones con 3 semillas sobreajusta, y la semilla pesa mucho (Q-learning en reversión: del 1 % al 29 %).
- **Limitaciones.** Al estado le faltan la distancia a la media y la volatilidad (ni MC lo compensa del todo); los mercados son simulados, con parámetros y comisión fijos, y el 10 % de ruido del ciclo da retornos irreales.
- **Además de lo pedido:** control MC con experimento controlado frente a Sarsa, análisis previo de la señal, dos reglas más, ajuste por etapas, 10 semillas nuevas en test, IC pareados, criterio de convergencia explícito y código reproducible con tests.